



# LingJingAPI

一键调用算力，简单好用。  
使用教学与 API 接口说明

这份文档面向首次安装用户和接口接入人员。客户端、AI 运行环境、模型和用户数据彼此分离；安装客户端后可一键拉取运行环境，只有网络失败时才需要手动下载。

|       |                                                                                             |
|-------|---------------------------------------------------------------------------------------------|
| 项目主页  | <a href="https://github.com/Yaro-lu/LingJingAPI">https://github.com/Yaro-lu/LingJingAPI</a> |
| 客户端版本 | 2.1.1                                                                                       |
| 支持系统  | Windows 10 22H2 / Windows 11, 64 位                                                          |
| 支持硬件  | NVIDIA RTX 20 系列或更高，显存 8GB 或以上；8GB 仅适合轻量 workflow，CUDA 13 环境要求 R580 或更高驱动                   |

Yaro-lu | 本地 AI 工作流服务

# 1. 安装与第一次启动

- 1. 双击轻量安装包，按提示完成安装。安装过程不需要管理员权限，也不会安装模型。
- 2. 安装完成后，桌面会出现两个使用同一 Logo 的入口：“LingJingAPI” 用于启动客户端，“LingJingAPI 示例页” 用于第一次体验接口。
- 3. 默认打开新手模式：环境或 Qwen3.5 缺失时，点击“一键修复”，自动准备运行环境和默认图文视频模型。已有可用环境会直接启动服务，不要求重新完成引导。
- 4. 修复前会显示环境与模型的完整下载量和本次剩余量，全新安装约下载 52.06 GB 或 67.30 GB。已有模型与断点会复用，进度按实际字节计算；下载完成后仍需安装、校验与启动验证，安装后磁盘占用另计。
- 5. 等待状态显示“启动成功”，点击“开始创作”，自动打开并连接示例页面。其他电脑或手机通过 URL + Key 调用。顶部居中切换新手 / 专家模式；专家模式保留原控制台、模型管理和设置。


自动下载失败时按弹窗中的备用网盘提示手动下载环境包，再导入本地环境包。大文件 SHA256 校验只在修复时进行，启动检测保持轻量。

运行环境包文件名：**runtime-nvidia-rtx20plus-cu130-v2.0.0.7z**  
项目主页：**<https://github.com/Yaro-lu/LingJingAPI>**

## 安装目录中的主要入口

| 名称                  | 用途                                  |
|---------------------|-------------------------------------|
| LingJingAPI         | 正式启动入口，使用项目 Logo                    |
| LingJingAPI示例页.html | 本地纯前端新手页面；填写 URL 和 Key 后自动检测模型并调用生成 |
| LingJingAPI使用教学.pdf | 当前使用教学与接口说明                         |
| models              | 用户模型目录，更新客户端时保留                     |
| outputs             | 生成结果目录                              |
| workflows           | 内置或导入的工作流定义                         |

# 图解 · 新手模式



无需填写配置：一键准备环境与模型，启动后提供 URL 与生成 Key。已有可用环境直接启动，截图中的首次引导提示以实际检测结果为准。需要更多管理功能时，切换顶部“专家模式”。

## 2. 环境、模型与 workflow

### 运行环境

运行环境包含便携 Python、ComfyUI、Torch/CUDA 和 Cloudflared。客户端会先校验环境包名称、精确大小、SHA256 和目录结构，再事务替换环境目录。模型、workflow 和生成结果不会因为环境修复而删除。

官方环境包版本、文件名、下载地址、大小和 SHA256 固定在客户端发布清单中。需要使用授权镜像时，可以在 runtime/config.local.txt 的 [runtime] 区域修改 HTTPS download\_url；镜像不能改变客户端内置的文件名、大小和 SHA256 校验。

### 模型

模型默认放在安装根目录的 models 文件夹，也可在“模型文件”中映射已有模型。修改目录后会扫描并适配相同的目录结构。优先使用可信来源的 safetensors 或 GGUF 文件，不要导入来源不明的传统 PyTorch checkpoint。

### workflow

每个 workflow 至少包含 manifest.json 和 workflow.json。manifest.json 定义公开调用名称、输入参数、输出类型和模型依赖。导入后应在“模型与环境”的 workflow 列表确认状态为“可以使用”。

### 专家模式的操作顺序

1. 安装或修复运行环境，并执行“检查环境”。
2. 导入 workflow 所需模型，然后点击“重新检查”。
3. 在“模型与环境”的 workflow 列表选择默认 workflow。
4. 回到控制台启动后台服务，复制 URL 和 API Key。
5. 在浏览器直接打开控制台的本地、局域网或公网 URL，填写 Key，连接后选择可用 workflow。原有独立 HTML 页面也可以继续使用。

客户端更新只替换程序文件；运行环境、模型、配置、日志和生成结果独立保存。卸载不会递归删除模型、生成结果、后装运行环境、用户配置和导入的 workflow；完成后会提示模型与生成结果的位置，可自行检查并删除。重要内容仍请独立备份。

### 3. API 接入基础

#### 新手示例页

“LingJingAPI示例页.html” 完全保存在本机，是一个不依赖额外服务的纯前端页面。可直接通过客户端 URL 打开，也可使用独立 HTML 文件。连接后只显示当前可用的工作流，选择后按该工作流加载参数。

在网页右上角填写 URL 和 API Key 后连接，右侧选择工作流并输入提示词。视频输入按工作流要求选择首帧、尾帧或参考图。连接信息会保存在当前浏览器，刷新时尝试自动连接一次，请在自己的设备上使用。

#### 地址与鉴权

控制台会显示公网、本地及局域网 BASE\_URL，以及生成接口使用的 API\_KEY。除 `/healthz` 外，业务接口通常需要在请求头中携带 Bearer Token。本机和支持的私有局域网地址可使用 HTTP，公网地址必须使用 HTTPS。手机建议在浏览器直接打开局域网 URL，并确保同一网络和 Windows 防火墙允许访问。

Authorization: Bearer API\_KEY  
Content-Type: application/json

#### 主要接口

| 方法   | 路径                            | 用途              |
|------|-------------------------------|-----------------|
| GET  | /healthz                      | 免鉴权的最小存活状态      |
| GET  | /v1/status                    | 客户端、环境和后台服务完整状态 |
| GET  | /v1/models                    | 当前可调用模型列表       |
| GET  | /v1/workflows                 | 工作流与公开调用名称列表    |
| POST | /                             | 运行当前选中的默认工作流    |
| POST | /workflow_alias               | 按公开名称运行指定工作流    |
| POST | /v1/chat/completions          | OpenAI 风格文字生成接口 |
| POST | /api/v3/images/generations    | 火山/即梦风格图片生成接口   |
| POST | /v1/workflows/run/workflow_id | 按工作流 ID 提交生成任务  |
| GET  | /v1/tasks/task_id             | 查询异步任务进度和结果     |
| GET  | /v1/tasks/queue               | 查看统一队列与排队位置     |
| POST | /v1/tasks/task_id/cancel      | 取消等待或运行中的任务     |
| GET  | /v1/files/task_id/filename    | 下载任务生成文件        |

创作页右侧的“接口文档”提供当前工作流的参数和调用示例。第三方先读取 GET /v1/workflows/workflow\_id/schema，再按该 schema 提交参数。

## 4. 调用示例与异步任务

不要把 API Key 写入公开网页、代码仓库、聊天截图或日志。公网 URL 是互联网入口，应和 API Key 一起妥善保存。

### 运行默认 workflow

```
curl -X POST "BASE_URL/" ^  
-H "Authorization: Bearer API_KEY" ^  
-H "Content-Type: application/json" ^  
-d "{\"prompt\":\"一只在窗边晒太阳的猫\"}"
```

### OpenAI 风格文字接口

```
curl -X POST "BASE_URL/v1/chat/completions" ^  
-H "Authorization: Bearer API_KEY" ^  
-H "Content-Type: application/json" ^  
-d "{\"model\":\"qwen3\",\"messages\": [{\"role\":\"user\",\"content\":\"写一段产品介绍\"}]}"
```

### 图片生成兼容接口

```
curl -X POST "BASE_URL/api/v3/images/generations" ^  
-H "Authorization: Bearer API_KEY" ^  
-H "Content-Type: application/json" ^  
-d "{\"prompt\":\"电影感城市夜景\",\"response_format\":\"url\"}"
```

### 异步任务流程

1. 生成接口返回 task\_id；多个入口共用任务队列，可查看 queue\_position。
2. 轮询 GET /v1/tasks/{task\_id}，直到状态变为完成、失败或取消。需要取消时 POST /v1/tasks/{task\_id}/cancel。
3. 从响应读取文件名或 URL。
4. 调用 GET /v1/files/{task\_id}/{filename} 下载结果。

## 5. 常见问题与安全说明

### 客户端能打开，但不能生成

轻量客户端只负责界面和环境维护。请先下载并安装独立运行环境包，再补齐 workflow 要求的模型。

### 一键修复拉取失败怎么办

失败弹窗会显示网络或下载错误，并提供可复制的 GitHub 地址。在项目 Releases 下载 7z 环境包，然后回到客户端选择本地环境包；客户端会使用内置 SHA256 校验。

### 环境检查提示 NVIDIA 驱动过旧

CUDA 13 运行环境要求使用 R580 或更高驱动。更新驱动后重启电脑，再点击“检查环境”。

### 接口返回 401 或 403

检查 Authorization 请求头是否使用 `Bearer API\_KEY`，并确认复制的是生成接口 Key，而不是本机管理 Key。

### 接口能访问但 workflow 失败

在“模型与环境”的工作流列表查看缺失模型和公开参数；确认模型文件完整，默认工作流已选中，ComfyUI 状态正常。

### 登录平台会同步什么

登录后会向你填写的服务端同步公网 URL、本机 API Key、设备名称、workflow/模型状态和不含提示词的任务进度，供平台调用。提示词与生成结果不在同步数据中；只应登录可信服务。不登录不影响完整本地功能。

### 更新客户端会不会删除模型

不会。程序、运行环境、模型和用户数据分离。重要模型和输出仍建议定期备份。

---

项目主页：<https://github.com/Yaro-lu/LingJingAPI>

建议始终从项目主页或明确授权的镜像获取安装包和环境包；客户端会用内置 SHA256 验证环境包。