



灵境 • LingJingAPI

一键调用算力，简单好用。
使用教学与 API 接口说明

这份文档面向首次安装用户和接口接入人员。客户端、AI 运行环境、模型和用户数据彼此分离；安装客户端后可一键拉取运行环境，只有网络失败时才需要手动下载。

项目主页	https://github.com/Yaro-lu/LingJingAPI
客户端版本	2.0.3
支持系统	Windows 10 22H2 / Windows 11, 64 位
支持硬件	NVIDIA RTX 20 系列或更高，显存 8GB 或以上；8GB 仅适合轻量工作流，CUDA 13 环境要求 R580 或更高驱动

Yaro-lu | 本地 AI 工作流服务

1. 安装与第一次启动

- 1. 双击轻量安装包，按提示完成安装。安装过程不需要管理员权限，也不会安装模型。
- 2. 安装完成后，桌面会出现两个使用同一 Logo 的入口：“灵境 · LingJingAPI” 用于启动客户端，“灵境 · LingJingAPI 示例页” 用于第一次体验接口。
- 3. 客户端界面可以立即打开；此时文字、图片和视频生成仍不可用，因为大型 AI 运行环境独立分发。
- 4. 进入“模型与环境”，安装或修复运行环境。客户端会自动拉取环境包，并使用内置 SHA256 校验，通过后直接安装。
- 5. 只有自动拉取失败时，客户端才会显示“自动修复失败”弹窗。可复制 GitHub 地址，手动下载环境包，再选择本地环境包完成安装。

运行环境包文件名：**runtime-nvidia-rtx20plus-cu130-v2.0.0.7z**
项目主页：**<https://github.com/Yaro-lu/LingJingAPI>**

安装目录中的主要入口

名称	用途
灵境 · LingJingAPI	正式启动入口，使用项目 Logo
灵境造片厂示例页.html	本地纯前端新手页面；填写 URL 和 Key 后自动检测模型并调用生成
灵境造片厂使用教学.pdf	当前使用教学与接口说明
models	用户模型目录，更新客户端时保留
outputs	生成结果目录
workflows	内置或导入的工作流定义

2. 环境、模型与 workflow

运行环境

运行环境包含便携 Python、ComfyUI、Torch/CUDA 和 Cloudflared。客户端会先校验环境包名称、精确大小、SHA256 和目录结构，再事务替换环境目录。模型、workflow 和生成结果不会因为环境修复而删除。

官方环境包版本、文件名、下载地址、大小和 SHA256 固定在客户端发布清单中。需要使用授权镜像时，可以在 runtime/config.local.txt 的 [runtime] 区域修改 HTTPS download_url；镜像不能改变客户端内置的文件名、大小和 SHA256 校验。

模型

模型默认放在安装根目录的 models 文件夹，也可在“模型文件”中映射已有模型。修改目录后会扫描并适配相同的目录结构。优先使用可信来源的 safetensors 或 GGUF 文件，不要导入来源不明的传统 PyTorch checkpoint。

workflow


每个 workflow 至少包含 manifest.json 和 workflow.json。manifest.json 定义公开调用名称、输入参数、输出类型和模型依赖。导入后应在“模型与环境”的 workflow 列表确认状态为“可以使用”。

推荐操作顺序

1. 安装或修复运行环境，并执行“检查环境”。
2. 导入 workflow 所需模型，然后点击“重新检查”。
3. 在“模型与环境”的 workflow 列表选择默认 workflow。
4. 回到控制台启动后台服务，复制 URL 和 API Key。
5. 在浏览器直接打开控制台的本地、局域网或公网 URL，填写 Key，连接后选择可用 workflow。原有独立 HTML 页面也可以继续使用。


客户端更新只替换程序文件；运行环境、模型、配置、日志和生成结果独立保存。卸载不会递归删除模型、生成结果、后装运行环境、用户配置和导入的 workflow；完成后会提示模型与生成结果的位置，可自行检查并删除。重要内容仍请独立备份。

图解 1 · 工作流、模型与环境




演示界面，状态数值为演示数据。工作流按钮集中在右侧，缺失模型可下载或映射已有文件。

图解 2 · 连接客户端



演示界面，公网地址与 Key 已替换为占位信息。本机、同 Wi-Fi 和公网分别使用对应的 URL。

图解 3 · 网页创作



实际创作页面：左侧管理项目，中间查看作品，右侧选择工作流与生成参数。图片点击加载原图，视频先加载首帧预览。

尝试：使用 FLUX.2 Klein 4B 输入“一只猫坐在杯子里”，生成后将图片加入参考图，再输入“把杯子换成红色”。这是操作示例，每次生成画面可能不同。

项目分类和历史保存在浏览器，切换 URL 或 Key 不会主动清空记录。删除项目仅移除分类；作品菜单中的“删除文件”会删除对应本地文件。当前按单用户使用，不做 Key 之间的作品隔离。

3. API 接入基础

新手示例页

“灵境造片厂示例页.html” 完全保存在本机，是一个不依赖额外服务的纯前端页面。可直接通过客户端 URL 打开，也可使用独立 HTML 文件。连接后只显示当前可用的工作流，选择后按该工作流加载参数。

在网页右上角填写 URL 和 API Key 后连接，右侧选择工作流并输入提示词。视频输入按工作流要求选择首帧、尾帧或参考图。连接信息会保存在当前浏览器，刷新时尝试自动连接一次，请在自己的设备上使用。

地址与鉴权

控制台会显示公网、本地及局域网 BASE_URL，以及生成接口使用的 API_KEY。除 `/healthz` 外，业务接口通常需要在请求头中携带 Bearer Token。本机和支持的私有局域网地址可使用 HTTP，公网地址必须使用 HTTPS。手机建议在浏览器直接打开局域网 URL，并确保同一网络和 Windows 防火墙允许访问。

Authorization: Bearer API_KEY
Content-Type: application/json

主要接口

方法	路径	用途
GET	/healthz	免鉴权的最小存活状态
GET	/v1/status	客户端、环境和后台服务完整状态
GET	/v1/models	当前可调用模型列表
GET	/v1/workflows	工作流与公开调用名称列表
POST	/	运行当前选中的默认工作流
POST	/ {workflow_alias}	按公开名称运行指定工作流
POST	/v1/chat/completions	OpenAI 风格文字生成接口
POST	/api/v3/images/generations	火山/即梦风格图片生成接口
POST	/v1/workflows/run/{workflow_id}	按工作流 ID 提交生成任务
GET	/v1/tasks/{task_id}	查询异步任务进度和结果
GET	/v1/tasks/queue	查看统一队列与排队位置
POST	/v1/tasks/{task_id}/cancel	取消等待或运行中的任务
GET	/v1/files/{task_id}/{filename}	下载任务生成文件

创作页右侧的“接口文档”提供当前工作流的参数和调用示例。第三方先读取 GET /v1/workflows/{workflow_id}/schema，再按该 schema 提交参数。

不要把 API Key 写入公开网页、代码仓库、聊天截图或日志。公网 URL 是互联网入口，应和 API Key 一起妥善保存。

4. 调用示例与异步任务

运行默认工作流

```
curl -X POST "BASE_URL/" ^  
-H "Authorization: Bearer API_KEY" ^  
-H "Content-Type: application/json" ^  
-d "{\"prompt\":\"一只在窗边晒太阳的猫\"}"
```

OpenAI 风格文字接口

```
curl -X POST "BASE_URL/v1/chat/completions" ^  
-H "Authorization: Bearer API_KEY" ^  
-H "Content-Type: application/json" ^  
-d "{\"model\":\"qwen3\",\"messages\":[{\"role\":\"user\",\"content\":\"写一段产品介绍\"}]}"
```

图片生成兼容接口

```
curl -X POST "BASE_URL/api/v3/images/generations" ^  
-H "Authorization: Bearer API_KEY" ^  
-H "Content-Type: application/json" ^  
-d "{\"prompt\":\"电影感城市夜景\",\"response_format\":\"url\"}"
```

异步任务流程

1. 生成接口返回 task_id; 多个入口共用任务队列, 可查看 queue_position。
2. 轮询 GET /v1/tasks/{task_id}, 直到状态变为完成、失败或取消。需要取消时 POST /v1/tasks/{task_id}/cancel。
3. 从响应读取文件名或 URL。
4. 调用 GET /v1/files/{task_id}/{filename} 下载结果。

5. 常见问题与安全说明

客户端能打开，但不能生成

轻量客户端只负责界面和环境维护。请先下载并安装独立运行环境包，再补齐 workflow 要求的模型。

一键修复拉取失败怎么办

失败弹窗会显示网络或下载错误，并提供可复制的 GitHub 地址。在项目 Releases 下载 7z 环境包，然后回到客户端选择本地环境包；客户端会使用内置 SHA256 校验。

环境检查提示 NVIDIA 驱动过旧

CUDA 13 运行环境要求使用 R580 或更高驱动。更新驱动后重启电脑，再点击“检查环境”。

接口返回 401 或 403

检查 Authorization 请求头是否使用 `Bearer API\_KEY`，并确认复制的是生成接口 Key，而不是本机管理 Key。

接口能访问但 workflow 失败

在“模型与环境”的工作流列表查看缺失模型和公开参数；确认模型文件完整，默认 workflow 已选中，ComfyUI 状态正常。

登录平台会同步什么

登录后会向你填写的服务端同步公网 URL、本机 API Key、设备名称、workflow/模型状态和不含提示词的任务进度，供平台调用。提示词与生成结果不在同步数据中；只应登录可信服务。不登录不影响完整本地功能。

更新客户端会不会删除模型

不会。程序、运行环境、模型和用户数据分离。重要模型和输出仍建议定期备份。

项目主页：<https://github.com/Yaro-lu/LingJingAPI>

建议始终从项目主页或明确授权的镜像获取安装包和环境包；客户端会用内置 SHA256 验证环境包。